

Veri Seti: RIAWELC – Kaynak Dikişı Kusurları için Radyografik Görüntü

Verinin Yayınlandığı Makele

RIAWELC Veri Seti Kullanılarak Kaynak Dikişı Kusurlarının Çok Sınıflı Sınıflandırılması

Emir Kaan SAIT

24501073

Literatür Analizi – 1. Çalışma: RIAWELC Veri Seti ve SqueezeNet Tabanlı Sınıflandırma

Problem Tanımı

- Radyografik (X-ray) görüntüler kullanılarak kaynak dikişlerinde oluşan kusurların otomatik olarak sınıflandırılması

Veri Seti (RIAWELC)

- Toplam 24.407 radyografik görüntü
- Görüntü boyutu: 224×224 , 8-bit gri seviye
- 4 sınıf:
 - CR – Crack (Çatlak): Kaynak bölgesinde çizgisel kırılmalar
 - PO – Porosity (Gözeneklilik): Gaz boşluklarından kaynaklanan yuvarlak yapılar
 - LP – Lack of Penetration (Nüfuziyet Eksikliği): Kaynağın tam birleşmemesi
 - ND – No Defect (Kusursuz): Herhangi bir kusur içermeyen kaynak
- Veri seti:
 - Train / Validation / Test olarak ayrılmış
 - Gerçek endüstriyel üretim ortamlarından elde edilmiş

Literatür Analizi – 1. Çalışma: RIAWELC Veri Seti ve SqueezeNet Tabanlı Sınıflandırma

Ön İşleme Adımları


- Görüntülere windowing işlemi uygulanarak kaynak dikişi bölgesinin yoğunluk aralığı sınırlandırılmış.
- Düşük kontrastlı kusur yapılarını daha belirgin hâle getirmek için CLAHE yöntemi kullanılmış.
- Görüntüler 224×224 boyutuna yeniden ölçeklendirilmiş ve veri seti standart bir formata getirilmiş.

		[6]	[7]	[16]	This work
Dataset		GDXray	GDXray	WDXI	RIALWEC
CNN Model	# Convolution Layers	0	19	4	20
	# Fully Connected Layers	5	2	1	0
	Image size	32×32	32×32	400×400	224×224
	Filters sizes	-	3×3 1×1	5×5 3×3	3×3
#Parameters		0.7M	3.125M	0.485M	0.69M
Memory required to store the parameters [Mbytes]		2.8	12.5	1.94	2.76
#classified defects		2	5	8	4
Test Accuracy		91.84%	96.88%	46.6%	93.33%

Literatür Analizi – 1. Çalışma: RIAWELC Veri Seti ve SqueezeNet Tabanlı Sınıflandırma

Model Yaklaşımı

- Düşük parametre sayısı ve hesaplama maliyeti avantajı nedeniyle SqueezeNet v1.1 mimarisi temel alınmış.
- Önceden eğitilmiş bu backbone üzerine, veri setine özgü bir sınıflandırma yapısı eklenerek model yeniden düzenlenmiş.
- Model; Adam optimizasyon algoritmasıyla, 32 batch size, 50 epoch boyunca 0.001 learning rate ile eğitilerek kaynak dikişi kusurlarının çok sınıflı olarak sınıflandırılması gerçekleştirilmiş.



Literatür Analizi – 2. Çalışma: ResNet Tabanlı Kaynak Kusuru Sınıflandırma Çalışması

Problem Tanımı

- Bu çalışmada, radyografik (X-ray) görüntüler üzerinden kaynak dikişlerinde oluşan kusurların otomatik olarak sınıflandırılması problemi ele alınmıştır. Çalışmanın temel amacı, daha derin konvolüsyonel sinir ağı mimarileri kullanılarak sınıflandırma doğruluğunu mümkün olan en üst seviyeye çıkarmaktır.

Veri Seti

- RIAWELC veri seti kullanılmıştır. Dört farklı sınıftan oluşmaktadır. Görüntüler stratified k-fold çapraz doğrulama yaklaşımıyla analiz edilmiştir. Bu sayede sınıf dağılımının dengeli biçimde korunması sağlanmış.


Ön İşleme Adımları

- Görüntüler öncelikle ResNet50 mimarisinin giriş boyutuna uygun olacak şekilde 224×224 piksel boyutuna yeniden ölçeklendirilmiştir. Eğitim aşamasında, modelin farklı geometrik ve fotometrik varyasyonlara karşı dayanıklılığını artırmak amacıyla rastgele döndürme, ölçekleme ve parlaklık değişimi gibi veri artırma teknikleri uygulanmış.

Literatür Analizi – 2. Çalışma: ResNet Tabanlı Kaynak Kusuru Sınıflandırma Çalışması

Model Yaklaşımı

- Çalışmada, derinliği ve güçlü özellik çıkarma kapasitesi nedeniyle ResNet50 mimarisi tercih edilmiş.
- Önceden eğitilmiş bu backbone üzerine, veri setine özgü bir sınıflandırma yapısı eklenerek model yeniden düzenlenmiş.
- Model; Adam optimizasyon algoritmasıyla, 32 batch size, 50 epoch boyunca 0.001 learning rate ile eğitilerek çok sınıflı olarak sınıflandırılması gerçekleştirilmiş.



Literatür Analizi – 3. Çalışma: VGG Tabanlı Kaynak Kusuru Sınıflandırma

Problem Tanımı

- Bu çalışmada, radyografik görüntüler kullanılarak kaynak dikişlerinde oluşan kusurların çok sınıflı olarak sınıflandırılması problemi ele alınmıştır. Çalışmanın temel amacı, özellikle görsel olarak birbirine benzeyen kusur tiplerinde, derin ağların daha zengin özellik temsilleri üretebileceği varsayımı üzerinden hareket edilmiş.

Veri Seti

- RIAWELC veri seti kullanılmıştır. Dört farklı sınıftan oluşmaktadır. Görüntüler stratified k-fold çapraz doğrulama yaklaşımıyla analiz edilmiştir. Bu sayede sınıf dağılımının dengeli biçimde korunması sağlanmış.


Ön İşleme Adımları

- Görüntüler öncelikle VGG tabanlı mimarilerin gerektirdiği şekilde 224×224 piksel boyutuna yeniden ölçeklendirilmiştir. Eğitim aşamasında, modelin farklı geometrik varyasyonlarına karşı dayanıklılığını artırmak amacıyla rastgele döndürme, yansıtma ve parlaklık değişimi gibi veri artırma teknikleri uygulanmış.

Literatür Analizi – 3. Çalışma: VGG Tabanlı Kaynak Kusuru Sınıflandırma

Model Yaklaşımı

- Çalışmada, derinliği ve güçlü özellik çıkarma kapasitesi nedeniyle WeldVGG mimarisi tercih edilmiş.
- Önceden eğitilmiş bu backbone üzerine, veri setine özgü bir sınıflandırma yapısı eklenerek model yeniden düzenlenmiş.
- Model; Adam optimizasyon algoritmasıyla, 32 batch size, 30 epoch boyunca 0.001 learning rate ile eğitilerek çok sınıflı olarak sınıflandırılması gerçekleştirilmiş.



Karşılaştırma Tablosu

- Derin mimariler (VGG16, ResNet50), daha düşük hata oranları sunmasına rağmen yüksek parametre ve hesaplama maliyetine sahiptir. SqueezeNet ise daha sade bir mimari yapıya sahip olup, derin ağlara kıyasla çok daha az parametre ile çalışmaktadır.
- SqueezeNet'in 1×1 konvolüsyonları yoğun şekilde kullanması, model boyutunun önemli ölçüde azalmasını sağlamaktadır. Fully connected katmanların kaldırılması ve Global Average Pooling kullanımı, parametre sayısını düşürürken aşırı öğrenme riskini azaltmaktadır.
- Hesaplama maliyeti açısından SqueezeNet, gerçek zamanlı ve kaynak kısıtlı sistemler için daha uygun bir yapı sunmaktadır.

Metrics	VGG16	GoogleNet	ResNet50	SqueezeNet V1.1
Top-5 error	7.4%	6.7%	5.3%	16.4%
Input size	224×224	224×224	224×224	224×224
# Conv/Fire Layers	13	57	53	10
Filter Sizes	3	1, 3, 5, 7	1, 3, 7	1,3
# FC Layers	3	1	1	0
# AGP Layer	0	0	0	1
Total Parameters	138M	7M	25.5M	1.24M
Total MACs	15.5G	1.43G	3.9G	349M


Metodolojiye Genel Bakış

Genel Yaklaşım

- Bu çalışmada, radyografik kaynak görüntülerinden kaynak dikişi kusurlarının çok sınıflı olarak sınıflandırılması hedeflenmiştir.
- Problem, görsel olarak birbirine benzeyen kusur tiplerinin ayırt edilmesini gerektirdiği için derin öğrenme tabanlı bir yaklaşım tercih edilmiştir.
- Metodoloji aşağıdaki ana adımlardan oluşmaktadır:
 - a. Veri setinin kullanımı
 - b. Veri ön-işleme ve veri artırma
 - c. CNN tabanlı model mimarisi tasarımı
 - d. Eğitim stratejisinin belirlenmesi

Veri Setinin Kullanımı

- RIAWELC veri seti, gerçek endüstriyel üretim ortamlarından elde edilmiş X-ray kaynak görüntülerini içermektedir. Bu veri seti 4 sınıftan oluşmaktadır:
 - **CR – Crack (Çatlak):** Kaynak dikişi boyunca oluşan çizgisel ve süreksiz yapılar.
 - **PO – Porosity (Gözeneklilik):** Gaz boşluklarından kaynaklanan yuvarlak veya düzensiz boşluklar.
 - **LP – Lack of Penetration (Nüfuziyet Eksikliği):** Kaynağın malzeme boyunca yeterince ilerlememesi sonucu oluşan kusur.
 - **ND – No Defect (Kusursuz):** Herhangi bir kusur içermeyen kaynak dikişleri.
- Bu sınıflar, görsel olarak birbirine benzer yapılar içerebildiği için problem zorluk derecesi yüksektir.




Veri Setinin Kullanımı

- RIAWELC veri seti, bildiride kullanıldığı şekilde training, validation ve test olarak önceden ayrılmıştır ve bu çalışma kapsamında aynen korunmuştur. Çünkü veri seti zaten rastgele (shuffle) ve sınıf dağılımı dengeli (stratified) olacak şekilde hazırlanmıştır.
- Mevcut bölünmenin korunmasıyla, veri sızıntısı riski ortadan kaldırılmış ve bildirideki sonuçlarla doğrudan karşılaştırılabilirlik sağlanmıştır.
- Validation set yalnızca model seçimi ve early stopping amacıyla kullanılmıştır. Test seti ise eğitim sürecine hiçbir aşamada dahil edilmemiştir.

Defect	Total	Train	Validation	Test
CR	7635	4962	1908	765
PO	6320	4108	1580	632
LP	4452	2893	1113	446
ND	6000	3900	1500	600
Total	24407	15863	6101	2443

Veri Ön-İşleme

- Radyografik görüntüler, derin öğrenme modellerinin beklediği giriş formatına uygun olacak şekilde 224×224 piksel boyutuna yeniden ölçeklendirilmiştir. Bu boyut ImageNet ön-eğitilmiş CNN mimarileriyle uyumluluk sağlamak amacıyla tercih edilmiştir.
- Tüm görüntülerin tek tip boyuta getirilmesiyle, eğitim sürecinde hesaplama tutarlılığı sağlanmış ve çözünürlük kaynaklı öğrenme hatalarının önüne geçilmiştir.
- Ön-işleme adımları, kusur bölgelerinin fiziksel ve geometrik yapısını bozmayacak şekilde kontrollü ve minimum düzeyde tutulmuştur.



Veri Artırma (Data Augmentation)

- Veri artırma işlemleri yalnızca training set üzerinde uygulanmıştır. Validation ve test setleri orijinal hâllerıyla korunmuştur.
- Eğitim verileri için düşük şiddetli veri artırma stratejisi benimsenmiştir:
 - **RandomRotation ($\pm 5^\circ$):** Görüntülerin küçük açısal varyasyonlara karşı dayanıklılığını artırmak amacıyla kullanılmıştır.
 - **ColorJitter (brightness=0.05, contrast=0.05):** Radyografik görüntülerdeki hafif yoğunluk ve kontrast değişimlerini simüle etmek için uygulanmıştır.
- Validation ve test setlerinde veri artırma uygulanmamıştır. Çünkü model performansının, gerçek ve değiştirilmemiş veriler üzerinde değerlendirilmesi hedeflenmiştir. Böylelikle eğitim aşamasında veri artırma yoluyla modelin genelleme yeteneği artırılırken, değerlendirme aşamasında ise tarafsız, güvenilir ve karşılaştırılabilir performans sonuçları elde edilmiştir.


Model Mimarisi

- Bu çalışmada özellik çıkarımı için SqueezeNet v1.1 mimarisi backbone olarak kullanılmış ve Fire9 modülüne kadar olan tüm katmanlar backbone kapsamında ele alınmıştır.
- Girişteki Conv1(3×3) ve takip eden MaxPool/2 katmanları sırasıyla, temel görsel özelliklerin(kenarlar, yoğunluk geçişleri) çıkarılması ve uzaysal boyutların kademeli olarak azaltılması amacıyla kullanılmıştır.
- SqueezeNet'in Fire modülleri, 1×1 squeeze ve 1×1–3×3 expand konvolüsyonlarından oluşarak düşük parametre sayısı ile etkili öznitelik temsilleri üretmektedir.
- Backbone, ImageNet ön-eğitilmiş ağırlıklar ile başlatılmış ve tamamen dondurularak (freeze) öğrenme süreci problem-özel sınıflandırma katmanlarına odaklanmıştır.




Model Mimarisi

- SqueezeNet backbone'un son katmanı olan Fire9 çıkışından, uzaysal boyutları korunmuş şekilde 512 kanallı özellik haritaları elde edilmiştir.
- Bu yüksek kanal sayısını azaltmak ve sınıflandırma için daha kompakt bir temsil oluşturmak amacıyla 1×1 konvolüsyon kullanılmış ve kanal sayısı $512 \rightarrow 256$ olarak belirlenmiştir.
- 256 kanal, bilgi kaybını sınırlarken parametre sayısını ve hesaplama maliyetini dengeleyen bir ara değer olarak seçilmiştir.
- 1×1 konvolüsyon sonrasında Batch Normalization eklenmiştir çünkü;
 - Aktivasyon dağılımlarını stabilize etmek,
 - Eğitim sürecini daha kararlı hâle getirmek,
 - Daha hızlı ve güvenilir yakınsama sağlamaktır.



Model Mimarisi

- ReLU aktivasyonu, non-linear'lik kazandırarak kusur sınıflarını ayırt edici daha zengin özniteliklerin öğrenilmesini sağlamaktadır.
- Global Average Pooling ile her kanal için uzaysal boyutlar ($H \times W$) üzerinde ortalama alındı. Uzaysal boyutlar 1×1 'e düşürüldü, kanal sayısı 256 olarak korundu. Kullanım nedeni parametre sayısını azaltmak ve overfitting riskini düşürmektir.
- Dropout ile sınıflandırma öncesinde rastgele nöronlar devre dışı bırakılıp aşırı öğrenme riski azaltılmıştır. Dropout oranı 0.4 seçildi çünkü modelin genelleme yeteneğini artırırken underfitting'e yol açmayacak orta düzey bir regularization sağladığı için tercih edilmiştir.
- Ardından Linear katman ($256 \rightarrow 4$) ile özellik vektörü dört sınıfa ait logit değerlerine dönüştürülerek nihai sınıflandırma gerçekleştirilmiştir.



Eğitim Stratejisi

- Model eğitimi için AdamW optimizasyon algoritması kullanılmıştır. Klasik Adam'a ek olarak weight decay'i gradyan güncellemesinden bağımsız uyguladığı için, özellikle sınıflandırma başlığında daha etkili regularization sağlamaktadır.
- Learning Rate = 10^{-4} olarak seçilmiştir. Çünkü;
 - Çok büyük olup kararsız güncellemelere yol açmamak,
 - Çok küçük olup yavaş öğrenmeye sebep olmamak amacıyla dengeleyici bir değer olarak tercih edilmiştir.
- Weight Decay = 10^{-4} kullanılarak, model ağırlıklarının aşırı büyümesi engellenmiş ve overfitting riski azaltılmıştır. Bu değer, Dropout ile birlikte orta düzey bir regularization sağlamak için seçilmiştir.

$$\theta_{t+1} = \theta_t - \eta \cdot (\hat{\mathbf{m}}_t / (\sqrt{\hat{\mathbf{v}}_t} + \epsilon) + \lambda \theta_t)$$

- Batch size, literatürdeki ilgili çalışmalarla uyumlu olacak şekilde 32 olarak belirlenmiştir.
- Problemin çok sınıflı sınıflandırma yapısına uygun olması nedeniyle Cross-Entropy Loss tercih edilmiştir.

Eğitim Stratejisi

- Eğitim süreci maksimum 100 epoch olarak tanımlanmıştır. Ancak model seçimi validation performansına göre yapılmıştır.
- En iyi model 63. epoch'ta elde edilen en yüksek validation accuracy'ye göre belirlenmiştir.
- Early Stopping, validation performansı 7 ardışık epoch boyunca iyileşme göstermediğinde eğitimi otomatik olarak sonlandıracak şekilde uygulanmıştır. Böylelikle gereksiz epoch hesabının önüne geçilmiştir ve aynı zamanda overfitting engellenmiştir.

```
Epoch [63/100] | Train Loss: 0.2716, Train Acc: 0.9004 | Val Loss: 0.1816, Val Acc: 0.9361
Epoch [64/100] | Train Loss: 0.2771, Train Acc: 0.8979 | Val Loss: 0.1906, Val Acc: 0.9351
↳ Early stopping counter: 1/7
Epoch [65/100] | Train Loss: 0.2753, Train Acc: 0.8986 | Val Loss: 0.1942, Val Acc: 0.9282
↳ Early stopping counter: 2/7
Epoch [66/100] | Train Loss: 0.2748, Train Acc: 0.9009 | Val Loss: 0.1926, Val Acc: 0.9305
↳ Early stopping counter: 3/7
Epoch [67/100] | Train Loss: 0.2674, Train Acc: 0.9017 | Val Loss: 0.1867, Val Acc: 0.9341
↳ Early stopping counter: 4/7
Epoch [68/100] | Train Loss: 0.2684, Train Acc: 0.8998 | Val Loss: 0.2000, Val Acc: 0.9276
↳ Early stopping counter: 5/7
Epoch [69/100] | Train Loss: 0.2700, Train Acc: 0.9025 | Val Loss: 0.2041, Val Acc: 0.9272
↳ Early stopping counter: 6/7
Epoch [70/100] | Train Loss: 0.2668, Train Acc: 0.9035 | Val Loss: 0.1882, Val Acc: 0.9328
↳ Early stopping counter: 7/7
```

Deneyysel Sonuçlar

- Bu bölümde, SqueezeNet tabanlı modelin kaynak dikiş kusuru sınıflandırma problemindeki performansı detaylı olarak incelenmiştir. Modelin başarımı; train, validation ve test veri kümeleri üzerinde elde edilen sonuçlar üzerinden değerlendirilmiştir.
- Deneyssel analiz kapsamında aşağıdaki tablo ve grafikler sunulmuştur:
 - Genel model başarımını gösteren accuracy ve loss değerleri,
 - Eğitim süreci boyunca modelin davranışını incelemek amacıyla train–validation accuracy ve loss grafikleri,
 - Sınıf bazlı performansı değerlendirmek için precision, recall ve F1-score sonuçları,
 - Modelin hangi sınıfları karıştırdığını analiz etmek amacıyla confusion matrix ve normalize edilmiş confusion matrix,
 - En sık karışan sınıf çiftlerini gösteren hata analiz tablosu.
- Bu analizler sayesinde modelin genelleme yeteneği, sınıflar arası dengesi ve hata eğilimleri kapsamlı bir şekilde değerlendirilmiştir.

Genel Performans Sonuçları (Accuracy & Loss)

- Model eğitim, doğrulama ve test veri kümelerinde tutarlı ve yüksek doğruluk elde etmiştir.
- Validation accuracy değerinin train accuracy değerinden yüksek olması, modelin overfitting yapmadığını ve iyi genelleme sağladığını göstermektedir.
- Eğitim ve doğrulama loss değerlerinin düşük ve birbirine yakın olması, öğrenme sürecinin kararlı ilerlediğini göstermektedir.
- Test accuracy ve test loss değerleri, modelin daha önce hiç görmediği veriler üzerinde de başarılı olduğunu doğrulamaktadır.

Metric	Value
Train accuracy	90.04%
Validation accuracy	93.61%
Train loss	0.2716
Validation loss	0.1816
Test accuracy	93.53%
Test loss	0.1847



Sınıf Bazlı Performans Sonuçları

- Model tüm sınıflarda yüksek ve dengeli F1-score değerleri elde etmiştir. Bu durum yalnızca accuracy'ye değil, sınıf bazlı başarının da güçlü olduğuna işaret eder.
- ND (No Defect) sınıfı en yüksek başarıya sahiptir. Bu kusursuz yüzeylerin ayırt edilmesinin model için daha kolay olduğunu göstermektedir.
- CR (Cracks) ve PO (Porosity) sınıflarında precision ve recall değerleri dengelidir. Model bu kusurları hem doğru tespit edebilmekte hem de yanlış alarm üretmemektedir.
- LP (Lack of Penetration) sınıfında F1-score diğer sınıflara kıyasla daha düşüktür. Bu durum, LP kusurlarının görsel olarak diğer kusurlarla daha fazla benzerlik göstermesinden kaynaklanmaktadır.
- Macro average ve weighted average değerlerinin birbirine yakın olması, sınıflar arasında ciddi bir dengesizlik problemi olmadığını göstermektedir.

	precision	recall	f1-score	support
CR	0.9512	0.9163	0.9334	765.0
PO	0.9652	0.9209	0.9425	632.0
LP	0.8476	0.9103	0.8778	446.0
ND	0.9551	0.9933	0.9739	600.0
accuracy	0.9353	0.9353	0.9353	0.0
macro avg	0.9298	0.9352	0.9319	2443.0
weighted avg	0.9369	0.9353	0.9356	2443.0

Confusion Matrix

- Diyagonal hücrelerdeki yüksek değerler, modelin genel olarak doğru sınıflandırma yaptığını göstermektedir.
- ND sınıfı neredeyse hatasız sınıflandırılmıştır. Bu durum, kusursuz kaynak görüntülerinin diğer kusurlu sınıflardan belirgin şekilde ayrıldığını göstermektedir.
- En belirgin karışma CR-LP sınıfları arasında gözlemlenmiştir. Bu kusurların görsel özelliklerinin birbirine benzer olması bu sonucu açıklamaktadır.





En Çok Karışan Sınıf Çiftleri

- Bu analiz, modelin en sık yaptığı yanlış sınıflandırmaları sınıf çiftleri bazında göstermektedir.
- En çok karışan sınıf çiftlerinin CR–LP ve PO–LP olduğu görülmektedir. Bunun temel nedeni, ilgili kusurların radyografik görüntülerde benzer yoğunluk dağılımları ve kenar yapıları içermesidir.
- ND sınıfının diğer sınıflarla neredeyse hiç karışmaması, modelin kusursuz kaynakları yüksek güvenilirlikle ayırt edebildiğini göstermektedir.

	true_class	pred_class	count	true_total	pct_of_true(%)
0	CR	LP	42	765	5.4902
1	PO	LP	27	632	4.2722
2	LP	CR	19	446	4.2601
3	PO	CR	17	632	2.6899
4	LP	ND	14	446	3.139
5	CR	PO	14	765	1.8301
6	CR	ND	8	765	1.0458
7	LP	PO	7	446	1.5695
8	PO	ND	6	632	0.9494
9	ND	LP	4	600	0.6667

Train ve Validation Set İçin Accuracy & Loss

- Eğitim süreci boyunca train ve validation loss eğrilerinin birlikte ve düzenli şekilde azalması, optimizasyon sürecinin kararlı ve sağlıklı olduğunu göstermektedir.
- Validation performansına göre 63. epoch'ta en iyi model seçilmiş, daha sonraki epoch'larda anlamlı bir iyileşme gözlemlenmemiştir.
- Bu sonuçlar, kullanılan regularization yöntemlerinin (data augmentation, dropout, weight decay ve early stopping) etkili olduğunu doğrulamaktadır.



Literatürdeki Çalışmalarla Karşılaştırma

- Literatürde RIAWELC veri seti üzerinde yapılan çalışmalarda, VGG16 ve ResNet50 gibi derin ve yüksek parametrelili mimariler kullanılarak %97–%98 seviyelerinde doğruluk değerleri raporlanmıştır. Ancak bu mimariler, çok yüksek parametre sayısına (yaklaşık 20 kat) ve dolayısıyla yüksek hesaplama maliyetine sahiptir.
- Ana referans alınan çalışmada kullanılan SqueezeNet tabanlı yaklaşım, daha hafif bir mimariyle daha düşük parametre sayısı kullanarak rekabetçi bir performans elde etmeyi hedeflemiştir. Bizim çalışmamızda ise yine SqueezeNet backbone korunmuş. Ancak sınıflandırma başlığı yeniden tasarlanarak parametre sayısı kontrollü şekilde artırılmıştır.
- Özelleştirilmiş head yapısı ve düzenleyici stratejiler sayesinde, referans SqueezeNet çalışmasına kıyasla daha yüksek doğruluk(%0.20) değeri elde edilmiş, buna karşın model hala VGG16 ve ResNet50 gibi mimarilere göre daha başarısız kalmıştır.

Sonuç ve Tartışma

- Referans çalışmaya kıyasla, yeniden tasarlanan sınıflandırma başlığı (head) sayesinde modelin ayırt edici gücü artırılmıştır; özellikle kanal sayısının 512'den 256'ya kontrollü şekilde indirildiği yapı, bilgi kaybı olmadan daha güçlü bir temsil sunmuştur.
- Batch Normalization, Dropout ve Weight Decay birlikte kullanılarak eğitim sürecinde kararlı bir optimizasyon sağlanmış, bu sayede overfitting gözlenmemiştir.
- Data augmentation'ın düşük şiddetli uygulanması, modelin genelleme yeteneğini artırmış; agresif dönüşümlerden kaçınılarak kusur yapılarının fiziksel anlamı korunmuştur.
- Confusion matrix ve hata analizleri, modelin özellikle LP sınıfında zorlandığını göstermektedir. Bu durum LP kusurlarının diğer kusur türleriyle görsel olarak benzer yapılar içermesiyle açıklanabilmektedir.

Genel Değerlendirme

- Bu çalışmada, SqueezeNet tabanlı derin öğrenme mimarisi kullanılarak radyografik kaynak kusuru sınıflandırma problemi ele alınmıştır.
- Ana referans alınan SqueezeNet çalışmasından farklı olarak, sınıflandırma başlığı yeniden tasarlanmış ve modelin ayırt edici gücünü artırmak amacıyla parametre sayısı artırılmıştır.
- Yapılan bu özgün mimari ve eğitimsel iyileştirmeler, modelin doğruluk ve sınıf bazlı performans değerlerini artırmıştır. Ancak hesaplama maliyetinde de yükselmeye yol açmıştır. Buna rağmen, önerilen yaklaşım hâlâ VGG16 ve ResNet50 gibi yüksek parametrelili mimarilere kıyasla çok daha hafif olup, performans–maliyet dengesi açısından rekabetçi bir çözüm sunmaktadır.
- Sonuç olarak bu çalışma, başarı oranı ile hesaplama maliyeti arasındaki dengenin mimari tasarım yoluyla bilinçli biçimde yönetilebileceğini göstermektedir. Ana referans çalışmanın parametre–verimlilik açısından hâlâ daha avantajlı olduğunu, buna karşın önerilen yaklaşımın daha yüksek doğruluk gerektiren senaryolar için güçlü bir alternatif sunduğunu ortaya koymaktadır.

Dinlediğiniz için Teşekkürler

Emir Kaan SAIT

24501073