

RIAWELC Veri Setinde Kaynak Kusurlarının Görüntü Tabanlı Sınıflandırılması için Özelleştirilmiş SqueezeNet Yaklaşımı

Emir Kaan SAIT

24501073

Yıldız Teknik Üniversitesi

İstanbul, Türkiye

kaan.sait@std.yildiz.edu.tr

Abstract—Bu çalışmada, endüstriyel kaynaklı metal yüzeylerde oluşan yapısal hataların otomatik olarak sınıflandırılması problemi ele alınmıştır. Kaynak hatalarının manuel yöntemlerle tespiti zaman alıcı, öznel ve hata payı yüksek bir süreçtir. Bu nedenle son yıllarda görüntü tabanlı derin öğrenme yöntemleri ön plana çıkmaktadır. Çalışmada RIAWELC veri seti kullanılmış ve hafif bir konvolüsyonel sinir ağı mimarisi olan SqueezeNet temel alınmıştır. Literatürde önerilen SqueezeNet tabanlı yaklaşımdan farklı olarak sınıflandırma başlığı yeniden tasarlanmış, düşük şiddette veri artırma uygulanmış ve AdamW optimizasyon algoritması tercih edilmiştir. Elde edilen sonuçlar, önerilen yaklaşımın düşük hesaplama maliyetine rağmen yüksek doğruluk ve dengeli sınıf bazlı performans sunduğunu göstermektedir.

Index Terms—Kaynak hatası tespiti, Derin öğrenme, SqueezeNet, Görüntü sınıflandırma, Endüstriyel kalite kontrol

I. GİRİŞ

Kaynak işlemleri, metal parçaların birleştirilmesinde endüstriyel üretimin temel adımlarından biridir. Ancak kaynak süreci sırasında ortaya çıkan çatlaklar (Crack), gözeneklilik (Porosity) ve nüfuziyet eksikliği (Lack of Penetration) gibi kusurlar, ürün dayanıklılığını ve güvenliğini ciddi şekilde olumsuz etkileyebilmektedir. Bu tür hataların üretim hattında erken aşamada tespit edilmesi, hem maliyetlerin düşürülmesi hem de ürün kalitesinin artırılması açısından kritik öneme sahiptir.

Geleneksel kaynak denetimi yöntemleri çoğunlukla uzman operatörlerin görsel incelemesine dayanmaktadır. Bu yaklaşım subjektif değerlendirmelere açık olması, insan yorgunluğu ve deneyim farklılıkları gibi nedenlerle tutarsız sonuçlar doğurabilmektedir. Ayrıca yüksek hacimli üretim hatlarında manuel kontrol yöntemleri pratik değildir. Bu nedenle otomatik ve güvenilir denetim sistemlerine olan ihtiyaç giderek artmaktadır.

Son yıllarda konvolüsyonel sinir ağları (CNN) görüntü sınıflandırma problemlerinde önemli başarılar elde etmiştir. Derin öğrenme tabanlı yaklaşımlar, karmaşık doku ve kenar yapılarının otomatik olarak öğrenilmesini sağlayarak klasik görüntü işleme yöntemlerine kıyasla üstün performans sunmaktadır. Bununla birlikte, çok derin ağların yüksek hesaplama maliyeti ve bellek gereksinimi, endüstriyel uygulamalarda önemli bir dezavantaj oluşturmaktadır.

Bu çalışmanın temel amacı, kaynak hatalarının sınıflandırılmasında hafif bir derin öğrenme mimarisi kullanarak yüksek doğruluk elde etmek ve hesaplama maliyetini makul seviyede tutmaktır. Bu doğrultuda SqueezeNet mimarisi temel alınmış, sınıflandırma başlığı yeniden tasarlanmış ve eğitim stratejileri optimize edilmiştir. Çalışmanın özgün katkıları şu şekilde özetlenebilir:

- SqueezeNet mimarisine özgün bir sınıflandırma başlığı eklenmesi,
- Düşük şiddette veri artırma stratejileriyle genelleme yeteneğinin artırılması,
- AdamW optimizasyon algoritmasının kullanımıyla daha dengeli öğrenme sağlanması,
- Literatürdeki ağır modellere kıyasla daha düşük parametre sayısı ile rekabetçi performans elde edilmesi.

II. İLGİLİ ÇALIŞMALAR

Kaynak hatalarının otomatik tespiti ve sınıflandırılması problemi literatürde farklı derin öğrenme mimarileri kullanılarak ele alınmıştır. Bu bölümde, çalışmamızla doğrudan ilişkili olan üç güncel akademik çalışma incelenmiştir.

Totino ve arkadaşları tarafından önerilen çalışmada, RIAWELC veri seti tanıtılmış ve SqueezeNet mimarisi kullanılarak kaynak hatalarının sınıflandırılması gerçekleştirilmiştir. Çalışmanın temel motivasyonu, düşük parametre sayısına sahip bir mimari ile kabul edilebilir doğruluk elde etmektir. Yaklaşık 1.24 milyon parametreye sahip olan bu model, hafifliği sayesinde endüstriyel uygulamalara uygunluk göstermektedir. Ancak sınıflandırma başlığının sınırlı temsil gücü nedeniyle doğruluk oranı %93.33 seviyesinde kalmıştır.

Palma-Ramírez ve arkadaşları ise ResNet50 mimarisini kullanarak kaynak hatalarının sınıflandırılmasını ele almıştır. Derin artık bağlantılara sahip bu mimari, oldukça yüksek temsil gücü sunmakta ve doğruluk oranlarını %98.75 seviyelerine kadar çıkarmaktadır. Bununla birlikte yaklaşık 25.5 milyon parametreye sahip olan ResNet50, hesaplama maliyeti ve bellek gereksinimi açısından endüstriyel ortamlarda kullanımı zor bir yapı sunmaktadır.

TABLE I: Literatürde Kullanılan Modellerin Karşılaştırılması

Çalışma	Mimari	Parametre	Accuracy
Totino et al.	SqueezeNet	1.24M	93.33
Palma-Ramírez et al.	ResNet50	25.5M	98.75
López et al.	WeldVGG	138M	~99
Bu Çalışma	Öz. SqueezeNet	1.32M	93.53

TABLE II: RIAWELC Veri Seti Dağılımı

Sınıf	Total	Train	Val	Test
CR	7635	4962	1908	765
PO	6320	4108	1580	632
LP	4452	2893	1113	446
ND	6000	3900	1500	600
Total	24407	15863	6101	2443

G. López ve çalışma arkadaşları tarafından önerilen VGG-tabanlı yaklaşımda ise daha derin bir konvolüsyonel yapı kullanılmıştır. VGG16 benzeri mimariler yaklaşık 138 milyon parametreye sahip olup yüksek doğruluk sağlamasına rağmen aşırı hesaplama yükü oluşturmaktadır. Bu durum, gerçek zamanlı uygulamalar ve gömülü sistemler için önemli bir kısıt oluşturmaktadır.

Bu çalışmaların özet bir karşılaştırması Tablo I'te sunulmuştur.

Tablodan görüldüğü üzere, ağır mimariler yüksek doğruluk sağlasa da hesaplama maliyetleri oldukça yüksektir. Bu çalışmada, hafif bir mimari korunarak doğruluk artırılmaya çalışılmıştır.

III. VERİ SETİ

Bu çalışmada RIAWELC veri seti kullanılmıştır. Veri seti, endüstriyel kaynak görüntülerinden oluşmakta ve dört farklı sınıf içermektedir:

- **CR (Crack):** Kaynak bölgesinde çatlaklar.
- **PO (Porosity):** Gaz boşlukları/gözeneklilik.
- **LP (Lack of Penetration):** Nüfuziyet eksikliği.
- **ND (No Defect):** Hatasız kaynak.

Her sınıf, farklı kaynak kusurlarını temsil etmekte olup görsel olarak bazı sınıflar arasında belirgin benzerlikler bulunmaktadır.

Veri seti, üretici tarafından eğitim, doğrulama ve test olmak üzere üç alt kümeye ayrılmıştır. Bu ayırım stratified şekilde yapılmış olup sınıf dağılımı tüm alt kümelerde korunmuştur. Veri setinin ayrıntılı dağılımı Tablo II'te verilmiştir.

IV. VERİ ÖN İŞLEME

Tüm görüntüler, SqueezeNet mimarisinin ImageNet ön eğitilmiş ağırlıklarıyla uyumlu olacak şekilde 224×224 boyutuna yeniden ölçeklendirilmiştir. Ayrıca görüntüler ImageNet ortalama ve standart sapma değerleri kullanılarak normalize edilmiştir. Bu işlem, önceden eğitilmiş ağırlık özelliği uzayına daha hızlı uyum sağlamasına yardımcı olmaktadır.




Fig. 1: Veri setinden örnek kaynak görüntüleri

V. VERİ ARTIRMA

Eğitim seti için düşük şiddette veri artırma uygulanmıştır. Rastgele ± 5 derece döndürme ve düşük oranlı parlaklık/kontrast değişimleri ile modelin farklı aydınlatma ve yönelim koşullarına karşı daha dayanıklı olması hedeflenmiştir. Doğrulama ve test setlerinde veri artırma uygulanmamış, yalnızca normalize edilmiş görüntüler kullanılmıştır. Bu yaklaşım, model performansının gerçek ve değiştirilmemiş veriler üzerinde tarafsız şekilde değerlendirilmesini sağlamaktadır.

VI. ÖNERİLEN MODEL MIMARISI

Bu çalışmada, kaynak hatalarının sınıflandırılması problemi için hafif ve hesaplama açısından verimli bir derin öğrenme mimarisi tercih edilmiştir. Temel mimari olarak SqueezeNet kullanılmış, ancak literatürde önerilen yapıdan farklı olarak sınıflandırma başlığı yeniden tasarlanmıştır. Bu bölümde, kullanılan mimari detayları ve yapılan özgün değişiklikler ayrıntılı olarak açıklanmaktadır.

A. SqueezeNet Omurgası (Backbone) ve Fire Modülleri

SqueezeNet, parametre sayısını minimize ederken temsil gücünü korumayı hedefleyen bir konvolüsyonel sinir ağı mimarisidir. Bu mimarinin temel yapı taşı olan *Fire* modülleri, squeeze ve expand katmanlarından oluşmaktadır. Squeeze katmanı 1×1 konvolüsyonlar kullanarak kanal sayısını azaltırken, expand katmanı 1×1 ve 3×3 konvolüsyonlar aracılığıyla özellik uzayını genişletmektedir. Bu yapı sayesinde klasik CNN mimarilerine kıyasla çok daha az parametre ile benzer seviyede temsil gücü elde edilebilmektedir.

Bu çalışmada SqueezeNet mimarisi Fire9 katmanına kadar aynen korunmuş ve ImageNet veri seti üzerinde önceden eğitilmiş ağırlıklar kullanılmıştır. Böylece model, genel görsel özellikleri öğrenmiş bir başlangıç noktasından eğitime başlamış ve daha hızlı yakınsama sağlamıştır.

B. Özgün Head Tasarımı

Literatürdeki temel SqueezeNet kullanımında sınıflandırma katmanı çoğu zaman tek bir 1×1 evrişim ile sınıf sayısına indirgeme ve ardından global pooling ile tamamlanır. Bu çalışmada doğruluğu artırmak amacıyla Fire9 çıkışından sonra daha zengin bir head tasarlanmıştır:

- **1×1 Conv (512 $\rightarrow$ 256):** Fire9 çıkışındaki 512 kanallı özellik haritası 256 kanala indirgenmiştir. 256 seçimi, (i) temsil kapasitesini artıracak kadar büyük, (ii) maliyeti kontrol edecek kadar küçük bir ara boyut sunar.
- **Batch Normalization + ReLU:** Aktivasyon dağılımını stabilize ederek öğrenmeyi hızlandırır ve içsel kovaryans kaymasını azaltır. ReLU ile doğrusal olmayanlık eklenir.




Fig. 2: Önerilen mimari: SqueezeNet omurgası korunmuş, Fire9 sonrası özelleştirilmiş head eklenmiştir.

- **Global Average Pooling:** Her kanalın $H \times W$ uzamsal boyuttaki değerlerinin ortalaması alınır; böylece her kanal 1×1 'e düşer. Kanal sayısı 256 olarak kalır, sadece uzamsal boyut küçülür.
- **Dropout ($p=0.4$):** Sınıflandırma aşamasında aşırı öğrenmeyi azaltmak için kullanılmıştır. 0.4 değeri, düzenleme etkisi ile öğrenme kapasitesi arasında dengeli bir nokta olarak seçilmiştir (çok büyük olursa underfitting riski artar).
- **Flatten + Linear ($256 \rightarrow 4$):** GAP sonrası $[B, 256, 1, 1]$ tensörü düzleştirilerek $[B, 256]$ yapılır ve son doğrusal katman ile 4 sınıfa logits üretilir.

VII. EĞİTİM YAPILANDIRMASI

Model eğitimi sırasında çok sınıflı sınıflandırma problemi için **Cross-Entropy** kayıp fonksiyonu kullanılmıştır. Optimizasyon algoritması olarak AdamW tercih edilmiştir. **AdamW**, klasik Adam algoritmasına ağırlık çürümesi (weight decay) ekleyerek genelleme performansını artırmaktadır.

Eğitim sürecinde kullanılan temel hiperparametreler şu şekildedir:

- Öğrenme oranı: 1×10^{-4}
- Weight decay: 1×10^{-4}
- Batch size: 32
- Maksimum epoch sayısı: 100

Modelin aşırı öğrenmesini önlemek amacıyla erken durma (early stopping) mekanizması kullanılmıştır. Doğrulama kaybı izlenmiş ve en iyi performans 63. epoch'ta elde edilmiştir. Eğitim bu noktada sonlandırılmış ve en iyi model ağırlıkları test aşamasında kullanılmıştır.

VIII. DENEYSEL SONUÇLAR

Bu bölümde, önerilen yöntemin performansı ayrıntılı olarak analiz edilmiştir. Elde edilen sonuçlar hem genel metrikler hem de sınıf bazlı değerlendirmeler üzerinden incelenmiştir.

A. Eğitim Süreci Analizi

Şekil 3 ve Şekil 4'ta eğitim ve doğrulama kümeleri için elde edilen doğruluk ve kayıp eğrileri sunulmaktadır. Eğitim sürecinin ilk epoch'larında her iki metrikte de hızlı bir iyileşme gözlemlenmiş, bu durum önceden eğitilmiş SqueezeNet omurgasının genel görsel özellikleri etkili biçimde transfer edebildiğini göstermiştir. İlerleyen epoch'larda doğruluk artışının daha yavaş ve kararlı bir şekilde devam ettiği, kayıp değerlerinin ise kademeli olarak azaldığı görülmektedir.

Doğrulama doğruluğunun eğitim doğruluğundan sistematik olarak daha yüksek seyretmesi, modelin aşırı öğrenme (overfitting) göstermediğine işaret etmektedir. Bu durum, eğitim




Fig. 3: Eğitim ve Doğrulama Doğruluk Eğrileri




Fig. 4: Eğitim ve Doğrulama Kayıp Eğrileri

aşamasında uygulanan veri artırma stratejileri ve dropout mekanizmasının yalnızca eğitim verisi üzerinde ek bir zorluk oluşturması, buna karşın doğrulama verisinin değiştirilmemiş olması ile açıklanabilir. Benzer şekilde, doğrulama kaybının eğitim kaybından daha düşük seviyelerde kalması, modelin genelleme yeteneğinin güçlü olduğunu desteklemektedir.

Eğitim ve doğrulama eğrileri arasında belirgin bir ayrışma veya ters yönde sapma gözlemlenmemesi, öğrenme sürecinin kararlı ilerlediğini ve erken durdurma mekanizmasının uygun bir noktada devreye girdiğini göstermektedir. Bu bulgular, önerilen mimari ve eğitim yapılandırmasının dengeli bir öğrenme süreci sağladığını ve test setinde elde edilen yüksek başarıyı desteklediğini ortaya koymaktadır.

B. Genel Performans Sonuçları

Tablo III, modelin eğitim, doğrulama ve test kümeleri üzerindeki genel başarımını özetlemektedir. Eğitim doğruluğunun %90.04, doğrulama doğruluğunun ise %93.61 olması, modelin aşırı öğrenme göstermeden genelleme yeteneği kazandığını ortaya koymaktadır. Bu durum, eğitim sürecinde uygulanan veri artırma ve düzenleme yöntemlerinin etkili olduğunu göstermektedir.

Kayıp değerleri incelendiğinde, doğrulama kaybının (0.1816) eğitim kaybından (0.2716) daha düşük olduğu görülmektedir. Test setinde elde edilen %93.53 doğruluk ve

TABLE III: Genel Başarım Sonuçları

Metric	Value
Train accuracy	90.04%
Validation accuracy	93.61%
Train loss	0.2716
Validation loss	0.1816
Test accuracy	93.53%
Test loss	0.1847

TABLE IV: Test Seti Sınıf Bazlı Performans

Class	Precision	Recall	F1-score	Support
CR	0.9512	0.9163	0.9334	765
PO	0.9652	0.9209	0.9425	632
LP	0.8476	0.9103	0.8778	446
ND	0.9551	0.9933	0.9739	600
Macro Avg	0.9298	0.9352	0.9319	2443
Weighted Avg	0.9369	0.9353	0.9356	2443

0.1847 kayıp değeri, doğrulama sonuçları ile tutarlı olup modelin farklı veri kümeleri üzerinde kararlı bir performans sergilediğini doğrulamaktadır.

C. Sınıf Bazlı Performans Analizi

Tablo IV, test seti üzerinde elde edilen sınıf bazlı precision, recall ve F1-score değerlerini göstermektedir. Sonuçlar incelendiğinde, ND sınıfının tüm metrikler açısından en yüksek performansı sergilediği ve model tarafından yüksek güvenle ayırt edilebildiği görülmektedir. Buna karşın, LP sınıfının F1-score değerinin diğer kusur sınıflarına kıyasla görece daha düşük olduğu dikkat çekmektedir. Bu durum, LP kusurlarının kaynak görüntülerinde CR sınıfı ile benzer kenar ve doku özellikleri sergilemesi nedeniyle, iki sınıf arasındaki ayrımın görece daha zor olmasından kaynaklanmaktadır.

D. Confusion Matrix Analizi

Şekil 5'te test seti için elde edilen ham karışıklık matrisi gösterilmektedir. Bu matris, sınıflar arasındaki mutlak doğru ve yanlış sınıflandırma sayılarını sunarak hata dağılımının nicel olarak incelenmesine olanak tanımaktadır.

Şekil 6'da ise normalize edilmiş karışıklık matrisi gösterilmektedir. Bu gösterim, her bir sınıf için yüzdesel başarı oranlarını ortaya koymakta ve sınıflar arası karışmaların göreceli etkisini daha net bir şekilde yansıtmaktadır. Özellikle CR ve LP sınıfları arasında belirli bir düzeyde karışma olduğu gözlemlenmekte olup, bu durum söz konusu kusur türlerinin benzer kenar ve doku özellikleri içermesinden kaynaklanmaktadır.

E. Hata Analizi

Tablo V test setinde gözlemlenen en sık sınıf karışmalarını nicel olarak ortaya koymaktadır. Sonuçlar incelendiğinde, en belirgin hata örüntüsünün LP sınıfının CR olarak tahmin edilmesi (LP→CR) ve ters yönde CR sınıfının LP olarak tahmin edilmesi (CR→LP) olduğu görülmektedir. Bu çift yönlü karışma, modelin iki kusur türü arasında ayırt edici özellikleri yeterince güvenilir biçimde yakalayamadığını göstermektedir.




Fig. 5: Test Seti Ham Karışıklık Matrisi




Fig. 6: Test Seti Normalize Edilmiş Karışıklık Matrisi

Bunun temel nedenlerinden biri, her iki kusur tipinin kaynak dikişi boyunca benzer kenar süreksizlikleri ve doğrusal yapı desenleri üretmesi; dolayısıyla düşük seviyeli (kenar/doku) özelliklerin birbirine yakın olmasıdır. Ayrıca, LP kusurlarının bazı örneklerinde çatlak benzeri ince ve keskin geçişlerin görülmesi, modelin aktivasyonlarının CR sınıfına kaymasına yol açabilmektedir.

Tablo V'te dikkat çeken bir diğer hata grubu PO sınıfının LP ve CR ile karışmasıdır (PO→LP ve PO→CR). Gözeneklilik kusurları yerel yoğunluk değişimleri ve noktasal/düzensiz boşluk yapıları ile karakterize edilse de, görüntüleme koşulları (aydınlatma, kontrast) veya kusurun küçük ölçekli ve yoğun bir bölgede kümelenmesi durumunda bu örüntüler, LP/CR sınıflarındaki düzensiz doku değişimleriyle benzer bir görünüm sergileyebilmektedir.

Son olarak, ND sınıfının oldukça düşük hata oranına sahip olması (ND→diğerleri sınırlı) modelin "hatasız" yüzey dokusunu yüksek güvenle ayırt edebildiğini göstermektedir.

TABLE V: Test Setinde En Sık Karıştırılan Sınıf Çiftleri

Gerçek Sınıf	Tahmin Edilen	Hata Sayısı	Toplam	Oran (%)
CR	LP	42	765	5.49
PO	LP	27	632	4.27
LP	CR	19	446	4.26
PO	CR	17	632	2.69
LP	ND	14	446	3.14
CR	PO	14	765	1.83
CR	ND	8	765	1.05
LP	PO	7	446	1.57
PO	ND	6	632	0.95
ND	LP	4	600	0.67

Buna karşın, kusurlu sınıflar arasındaki karışmalar, sınıfların görsel benzerliğinin yanı sıra kusurların şiddetinin değişken olması ve kusurun görüntü içinde kapladığı alanın sınırlı kalması gibi etkenlerle de ilişkilendirilebilir. Bu bulgular, LP–CR ayrımının iyileştirilmesi için daha ayırt edici özelliklerin öğrenilmesini destekleyecek veri artırma stratejileri veya sınıf odaklı kayıp fonksiyonları gibi yaklaşımların ileride değerlendirilebileceğine işaret etmektedir.

IX. SONUÇ VE TARTIŞMA

Bu çalışmada, SqueezeNet omurgası üzerine inşa edilen özelleştirilmiş bir sınıflandırma başlığı kullanılarak, hafif bir mimari korunurken sınıflandırma doğruluğunun artırılması hedeflenmiştir. Elde edilen sonuçlar, önerilen yaklaşımın yüksek doğruluk sağlarken aynı zamanda düşük hesaplama maliyeti avantajını koruduğunu göstermektedir. Literatürde ResNet50 ve VGG-türevi ağların daha yüksek doğruluklara ulaşabildiği rapor edilse de, bu mimarilerin sahip olduğu yüksek parametre sayıları, özellikle gerçek zamanlı veya düşük kaynaklı endüstriyel ortamlarda uygulanabilirliği sınırlandırmaktadır.

Bu çalışma kapsamında kullanılan RIAWELC veri seti, endüstriyel kaynak hatalarının görüntü tabanlı analizi için açık erişimli bir referans veri seti olup <https://github.com/stefyste/RIAWELC> adresi üzerinden kamuya açık şekilde sunulmaktadır. Veri setinin farklı kusur türleri arasında belirgin görsel benzerlikler içermesi, sınıflandırma problemini daha zorlayıcı hâle getirmekte ve önerilen yaklaşımın genelleme yeteneğinin değerlendirilmesi açısından anlamlı bir test ortamı sağlamaktadır.

Önerilen yöntem, temel SqueezeNet tabanlı çalışmalara kıyasla doğruluk oranını artırırken, parametre sayısında sınırlı bir artışa neden olmuştur. Bu durum, elde edilen kazanımın bir “maliyet–başarım değiş tokuşu” (trade-off) olarak değerlendirilmesini gerekli kılmaktadır. Buna rağmen model, hâlâ ağır mimarilere kıyasla oldukça hafif bir yapı sunmaktadır. Ayrıca gerçekleştirilen hata analizi, modelin özellikle CR ve LP sınıfları arasında ayrım yapmakta zorlandığını göstermiştir. Gelecek çalışmalarda, bu iki sınıfın daha iyi ayrıştırılabilmesi için sınıf odaklı veri artırma stratejileri veya daha seçici kayıp fonksiyonları (örneğin focal loss) gibi yöntemler değerlendirilebilir. Ancak bu çalışmada, tek bir deneysel yapı korunarak önerilen mimarinin etkisi yalın bir biçimde incelenmiştir.

REFERENCES

- [1] Totino et al., “RIAWELC Dataset and SqueezeNet-Based Welding Defect Classification,” 2021.
- [2] Palma-Ramírez et al., “Deep Residual Networks for Welding Defect Detection,” 2022.
- [3] G. López et al., “VGG-Based CNN Models for Welding Inspection,” 2020.